

Segmentación de imágenes



Segmentación de imágenes

Subdivisión de la imagen en zonas o clases disyuntas para identificar estructuras u objetos presentes en la imagen



Zonas de interés en la imagen
Identificadas por similitud/discontinuidad

Segmentación de imágenes

Operación de mapeo desde una imagen o conjunto de $N \times M$ píxeles hacia un conjunto finito de clases C

$$S: N \times M \rightarrow C$$

$$C = \{ 1, 2, \dots, k \}$$

Determinado por:

- Dominio del problema
- Meta de operación de la segmentación



Sea R : representación de la región completa de una imagen

Segmentación = proceso que divide R en n subregiones $R_1, R_2, \dots, R_n$ de tal forma que:

$\bigcup_{i=1}^n R_i = R$ la segmentación debe ser completa (cada píxel pertenece a una región)

R_i es una región conexa, $i = 1, \dots, n$

$R_i \cap R_j = \emptyset \quad \forall i, j, i \neq j$: las regiones son disyuntas

$Q(R_i) = \text{VERDADERO}, i = 1, \dots, n$

$Q(R_i \cup R_j) = \text{FALSO}, \text{ para } i \neq j$



$Q(R_i)$: predicado lógico sobre los puntos de R_i .
Propiedades que deben satisfacer los píxeles de una
región segmentada



Regiones resultantes

- Uniformes y homogéneas con respecto a alguna característica de la imagen
 - nivel de gris
 - textura

Regiones adyacentes

- Valores significativamente diferentes con respecto a la característica de uniformidad


Fronteras/límites

- Lo más simples posibles
- Sin dentados o irregularidades



Segmentación por contornos

Búsqueda de discontinuidades en la intensidad de los niveles de gris de la imagen



Segmentación por regiones

Búsqueda de las áreas homogéneas



Ejemplos



Segmentación por
contornos



Segmentación por
regiones



a	b	c
d	e	f

FIGURE 10.1

(a) Image of a constant intensity region.


(b) Boundary based on intensity discontinuities.

(c) Result of segmentation.

(d) Image of a texture region.

(e) Result of intensity discontinuity computations (note the large number of small edges).

(f) Result of segmentation based on region properties.




Se ve pixelada porque la imagen fue dividida en subregiones de 8x8 para segmentarlas por separado (y todos los píxeles de cada subregión fueron etiquetados con la misma intensidad)

Enfoque región: Segmentación basada en la extracción de regiones



Segmentación por regiones



Objetivo:

- Dividir una imagen en regiones

3 familias de métodos:

- ✓ Umbralización
- ✓ Crecimiento de regiones
- ✓ División y fusión de regiones

Umbralización



Umbralización

- Proceso de segmentación por regiones más simple.
- No cumple siempre con la condición de conectividad (regiones conexas)



Transformación de una imagen de entrada f en una imagen binaria (segmentada) de salida g :

$$g(x, y) = \begin{cases} 1 & f(x, y) > T \\ 0 & f(x, y) \leq T \end{cases}$$

$g(x, y) = 1 \rightarrow$ píxeles de objetos de la imagen

$g(x, y) = 0 \rightarrow$ píxeles del fondo de la imagen



T puede ser vista como una función

$$T = T[\underbrace{x, y}_{\text{posición del punto}}, \underbrace{p(x, y)}_{\text{propiedad local del punto. Ej: media del NG de un vecindario centrado en (x,y)}], \underbrace{f(x, y)}_{\text{nivel de gris del punto}}]$$

posición
del punto

propiedad local del
punto. Ej: media
del NG de un
vecindario
centrado en (x,y)

nivel de
gris del
punto




T puede ser global o local

$$T = T[x, y, p(x, y), f(x, y)]$$

Global

- Sólo depende de $f(x, y)$
- Es único para toda la imagen



Local

- Depende de $f(x, y)$ y de $p(x, y)$
- La imagen es dividida en subimágenes y se determina un valor de umbral para cada subregión.
- Si además depende de la posición (x, y) se llama umbral adaptativo o dinámico

Generalización de la umbralización global
=
Umbralización por bandas

$$g(x, y) = \begin{cases} 1 & f(x, y) \in D \text{ Conjunto de niveles de gris} \\ 0 & \text{dlc} \end{cases}$$



Global

Un solo umbral global

Local

- División de la imagen en subimágenes
- Umbralización de cada subimagen por separado
Se puede definir el umbral local interpolando los umbrales de las subimágenes vecinas

Multinivel

Varios umbrales → Varias regiones resultantes

Multiespectral o multicanal o basada en varias variables

Para segmentar imágenes donde cada pixel es caracterizado por más de una variable. Ej. Imágenes en color


Umbralización global





Histograma bi-modal

Histograma tri-modal



Diferentes métodos de umbralización global



Promedio

Punto medio

P-mosaico o p-tile


Método del modo

Optimizaciones del método del modo

Umbralización global iterativa

OTSU


Diferentes métodos de umbralización global



Diferentes métodos de umbralización global



Promedio



$$t^* = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y)$$

Diferentes métodos de umbralización global




Punto medio

Diferentes métodos de umbralización global



Punto medio

$$t^* = \frac{l_{\min} + l_{\max}}{2}$$



Diferentes métodos de umbralización global




P-mosaico o p-tile

Diferentes métodos de umbralización global



P-mosaico o p-tile




- Asume que la imagen consta de objetos bastantes contrastados con el fondo.
- Se necesita conocer el porcentaje de la imagen que ocupan los objetos (valor a) = tamaño en píxeles del objeto.

Diferentes métodos de umbralización global



P-mosaico o p-tile



$$t^* = \left\{ t_{\max} \left| \frac{\# \text{ pixeles} - \text{objeto}}{\# \text{ pixeles} - \text{imagen}} * 100 \geq a\% \right. \right\}$$

Diferentes métodos de umbralización global



Método del modo

Diferentes métodos de umbralización global





Método del modo

Aplica a imágenes con histogramas aproximadamente bimodales



$t^*=80$

t^* = nivel de gris
que se encuentra
en el valle que
separa los dos
modos del
histograma



Diferentes métodos de umbralización global



Método del modo

¿Cómo hallar el valle entre los dos modos del histograma?

1. Encontrar los dos máximos locales de mayor valor en el histograma
2. Buscar el valor mínimo entre estos 2 máximos

Diferentes métodos de umbralización global



Método del modo



¿Cómo hallar el valle entre los dos modos del histograma?

1. Encontrar los dos máximos locales de mayor valor en el histograma
2. Buscar el valor mínimo entre estos 2 máximos

Para evitar la detección de 2 máximos locales que pertenezcan al mismo modo (al mismo máximo global):

- Se fija una distancia mínima en NG entre los máximos locales
- Se filtra el histograma

Filtrado del histograma



$$h'(z) = \frac{1}{2K+1} \sum_{i=-K}^K h(z+i)$$

Diferentes métodos de umbralización global



Buscar el umbral que maximiza la varianza entre objetos y fondo (varianza interclases)

Optimizaciones del método del modo

Umbralización global iterativa

OTSU

Umbralización global iterativa



Optimizaciones del método del modo

1. Seleccionar un valor de umbral t cualquiera (puede ser la media de la intensidad de los píxeles en la imagen)
2. Segmentar la imagen usando t
3. Calcular las medias de intensidad de cada región.
4. Calcular el nuevo umbral t_k
5. Repetir pasos 1- 4 hasta que la diferencia de t en dos iteraciones consecutivas sea inferior a un épsilon

$$\mu_b^k = \frac{\sum_{(i,j) \in C_b} f(i,j)}{\text{\#píxeles en } C_b}$$

$$\mu_n^k = \frac{\sum_{(i,j) \in C_n} f(i,j)}{\text{\#píxeles en } C_n}$$


$$t_k = \frac{\mu_n^k + \mu_b^k}{2}$$

$$t_{k+1} \approx t_k$$


Umbralización global iterativa



Optimizaciones del
método del modo



$$t^*=125$$





Optimizaciones del método del modo

- Calcula el valor umbral de forma que la dispersión dentro de cada clase sea lo más pequeña posible, pero al mismo tiempo la dispersión sea lo más alta posible entre clases diferentes.
- Calcula el cociente entre ambas variancias y se busca un valor umbral para el que este cociente sea máximo.



Optimizaciones del método del modo

1. Calcular el histograma normalizado $p_i = \frac{n_i}{MN}$
2. Seleccionar un umbral k .
3. Calcular la probabilidad de ocurrencia de cada clase. $\sum_{i=0}^{L-1} p_i = 1 \quad p_i \geq 0$
4. Calcular el nivel de gris promedio de los píxeles asignados a cada clase. $P_1(k) = \sum_{i=0}^k p_i$
 $P_2(k) = \sum_{i=k+1}^{L-1} p_i = 1 - P_1(k)$
5. Calcular el nivel de gris promedio de TODA la imagen $m_1(k) = \frac{1}{P_1(k)} \sum_{i=0}^k ip_i$
 $m_2(k) = \frac{1}{P_2(k)} \sum_{i=k+1}^{L-1} ip_i$
 $m_G = \sum_{i=0}^{L-1} ip_i$
6. Calcular la varianza inter-clase $\sigma_B^2 = P_1(m_1 - m_G)^2 + P_2(m_2 - m_G)^2$
7. Buscar el umbral OTSU k^* que maximice la varianza inter-clases. $\sigma_B^2(k^*) = \max_{0 \leq k \leq L-1} \sigma_B^2(k)$


Diferentes métodos de umbralización global



Optimizaciones del
método del modo

→ OTSU

Imagen original



Histograma

Resultado con
umbralización
global iterativa

Resultado con Otsu

Mejoras a la umbralización global





Filtrado previo de la imagen

Eliminar ruido que puede perturbar el proceso de selección automática de un umbral (puntos que no pertenecen a clases verdaderas)

Detección previa de contornos

En el proceso de selección del umbral, incluir únicamente puntos sobre los contornos y cercanos a éstos (de cada lado).

Histogramas con picos de altura similar (uno para el fondo y otro para el objeto)

Filtrado previo de la imagen



Imagen original

Histograma

Imagen segmentada con Otsu




Imagen filtrada
Promedio 5x5

Histograma

Imagen segmentada con Otsu

Depende del tamaño de los objetos



Imagen original

Histograma

Imagen segmentada con Otsu




Imagen filtrada
Promedio 5x5

Histograma

Imagen segmentada con Otsu

El filtrado no
funcionó



Depende del tamaño de los objetos



Imagen original

Histograma

Imagen segmentada con Otsu




Imagen filtrada
Promedio 5x5

Histograma

Imagen segmentada con Otsu

Solución:
detección
previa de
contornos ...

Solución: detección previa de contornos ...

Pasos a seguir:

Imagen de entrada



1. Calcular los contornos (bordes) de la imagen $f(x, y)$ usando la magnitud del gradiente o el valor absoluto del Laplaciano ([se verán más adelante en el curso](#))
2. Especificar un valor de umbral T sobre estos puntos de contorno
3. Umbralizar la imagen del paso 1 utilizando el umbral del paso 2, para producir una imagen binaria $g_T(x, y)$. Esta imagen es utilizada como una “máscara” en el siguiente paso, para seleccionar los píxeles de $f(x, y)$ que corresponden a píxeles de contorno.
4. Calcular un histograma utilizando únicamente los píxeles de $f(x, y)$ que corresponden a las posiciones de los píxeles con valor 1 en $g_T(x, y)$.
5. Utilizar el histograma del paso 4 para segmentar $f(x, y)$ globalmente, usando por ejemplo OTSU.



Imagen de salida

Solución: detección previa de contornos ...

Pasos a seguir:

Imagen de entrada



1. Calcular los contornos (bordes) de la imagen $f(x, y)$ usando la magnitud del gradiente o el valor absoluto del Laplaciano (se verán más adelante en el curso)
2. Especificar un valor de umbral T sobre estos puntos de contorno
3. Umbralizar la imagen del paso 1 utilizando el umbral del paso 2, para producir una imagen binaria $g_T(x, y)$. Esta imagen es utilizada como una “máscara” en el siguiente paso, para seleccionar los píxeles de $f(x, y)$ que corresponden a píxeles de contorno.
4. Calcular un histograma utilizando únicamente los píxeles de $f(x, y)$ que corresponden a las posiciones de los píxeles con valor 1 en $g_T(x, y)$.
5. Utilizar el histograma del paso 4 para segmentar $f(x, y)$ globalmente, usando por ejemplo OTSU.



Imagen de salida

Normalmente es un percentil alto (~ 90) para usar pocos puntos en el cálculo


Detección previa de contornos



Imagen original

Histograma

Máscara = gradiente umbralizado (99.7%)



Original * máscara

Histograma de puntos NO
negros

Imagen original segmentada con
Otsu calculado a partir del
histograma anterior (umbral final =
134)


Detección previa de contornos



Imagen original

Histograma

Imagen segmentada con Otsu ($t^* = 42$)



Valor absoluto del
Laplaciano
umbralizado (99.5%)

Histograma de puntos
NO negros (original *
máscara)

Imagen original segmentada con
Otsu calculado a partir del
histograma anterior ($t^* = 115$)

CUIDADO con el umbral del contorno




Con un valor absoluto BAJO del Laplaciano
umbralizado (53.9%)

Umbralización múltiple




Múltiples umbrales



- ❖ Cuando es necesario dividir la imagen en varias regiones, caracterizadas por diferentes niveles de gris
- ❖ Varios umbrales
- ❖ Varias regiones resultantes

$$g(x, y) = \begin{cases} a & \text{si } f(x, y) > T_2 \\ b & \text{si } T_1 < f(x, y) \leq T_2 \\ c & \text{si } f(x, y) \leq T_1 \end{cases}$$

Generalización umbralización multinivel

$$g(x, y) = \begin{cases} 1 & \text{si } f(x, y) \in D_1 \\ 2 & \text{si } f(x, y) \in D_2 \\ \dots & \\ n & \text{si } f(x, y) \in D_n \\ 0 & \text{dlc} \end{cases}$$


Conjuntos de niveles de gris

Dificultad: determinar los D_i o los umbrales T_i que aíslen las regiones, sobretodo cuando el # de modos del histograma es >>




Múltiples umbrales

Análisis de
concavidad del
histograma

Otsu con
múltiples
umbrales


Análisis de concavidad del histograma



Concavidad: paso de un pico a otro, pero que no es necesariamente un valle


Puntos candidatos a umbral

1. Calcular el histograma de la imagen $h(q)$ con los valores de gris $q_0, q_1, \dots, q_{L-1}$
2. Construir el polígono convexo $\bar{h}$ más pequeño que contenga $h(q)$





3. Determinar las concavidades a partir de $\bar{h} - h$



q_i es candidato a umbral si $\bar{h}(q_i) - h(q_i)$ tiene un máximo local

4. Suprimir máximos locales falsos introducidos por ruido impulsional

Otsu con múltiples umbrales



1. Calcular la varianza inter-clase con k clases:

$$\sigma_B^2 = \sum_{k=1}^K P_k (m_k - m_G)^2$$

Probabilidad de la
clase C_k

————— $P_k = \sum_{i \in C_k} p_i$

Nivel de gris
promedio de la clase
 C_k

————— $m_k = \frac{1}{P_k} \sum_{i \in C_k} ip_i$

2. Las k clases están separadas por $k-1$ umbrales que maximizan σ_B^2

Ejemplo de Otsu con 2 umbrales




Imagen original

Imagen segmentada (3 clases)

Umbralización local adaptativa




División de la imagen en subregiones



Imagen original

Histograma

Segmentación global iterativa




Otsu

Imagen dividida en 6 subimágenes

Otsu en cada subregión

¿Por qué funciona?




Los histogramas de cada subregión son bimodales




Los objetos de interés y el fondo ocupan regiones de tamaño comparable

¿Cuándo no funciona?



Cada subimagen, segmentada por separado con umbralización iterativa

Ejemplo de subimágenes correcta e incorrectamente segmentadas



Adaptación del umbral a las propiedades locales de la imagen



+ Varias opciones para el umbral T_{xy} :

$$T_{xy} = a\sigma_{xy} + bm_{xy}$$

$$T_{xy} = a\sigma_{xy} + bm_G$$

Calcular un umbral en cada punto (x, y) con base en una o más propiedades calculadas en un vecindario S_{xy} de (x, y)

+ Umbralización:

$$g(x, y) = \begin{cases} 1 & f(x, y) > T_{xy} \\ 0 & f(x, y) \leq T_{xy} \end{cases}$$

Esta ecuación es evaluada en cada píxel de la imagen y un umbral diferente es calculado en cada posición (x, y) utilizando los píxeles del vecindario S_{xy}

Adaptación del umbral a las propiedades locales de la imagen



+ Generalización de la umbralización:


$$g(x, y) = \begin{cases} 1 & \text{si } Q(\text{local}) = \text{VERDADERO} \\ 0 & \text{dnc} \end{cases}$$

Q es un predicado (propiedad) basado en parámetros calculados usando los píxeles en el vecindario S_{xy} de (x, y)





Adaptación del umbral en función de las propiedades locales de la imagen

Imagen original



Otsu con 2 umbrales

Imagen de desviaciones
estándar locales
(3x3)



Resultado con
umbralización local


$$g(x, y) = \begin{cases} 1 & \text{si } f(x, y) > 30 * \sigma_{xy} \text{ AND } f(x, y) > 1.5m_G \\ 0 & \text{dlc} \end{cases}$$

Se escoge promedio global porque el fondo es bastante homogéneo y más oscuro que los objetos





Adaptación del umbral en función de las propiedades locales de la imagen

Imagen original



Otsu con 2 umbrales

Imagen de desviaciones
estándar locales
(3x3)



Resultado con
umbralización local

$$g(x, y) = \begin{cases} 1 & \text{si } f(x, y) > 30 * \sigma_{xy} \text{ AND } f(x, y) > 1.5m_G \\ 0 & \text{dlc} \end{cases}$$

Comentario de González: "these values were determined experimentally, as is usually the case in applications such as this"

Crecimiento de regiones





Píxeles son agrupados según doble criterio:

Homogeneidad:
determinada por un
predicado

- Geométrico: forma de la región (rectangular, convexa,...)
- Fotométrico
- Combinación de los dos


Adyacencia

- Vecinos-4
- Vecinos-8

Ejemplos de predicados de homogeneidad para una región R



- La varianza $\sigma^2(R)$ de R es inferior a t
- El número $\alpha(R)$ de puntos cuyo nivel de gris se sitúa fuera del intervalo $[\mu(R) - \sigma(R), \mu(R) + \sigma(R)]$ es inferior a un umbral t^*





1


Selección del (de los) pixel(es) semilla inicial(es)

- Si se parte de un único pixel semilla, 1 sola región crece antes que las otras → segmentación sesgada a favor de esta región

Solución: *varias semillas*

- Escogencia de diferentes semillas puede producir resultados diferentes:
¿CÓMO ESCOGER SEMILLAS?
 - Información a priori (se conoce el problema)
 - Determinar agrupaciones de píxeles dentro de la imagen según el predicado que se va a usar y tomar los centroides de estas agrupaciones

Ejemplo de segmentación por el método de crecimiento de regiones




Resultado del crecimiento de regiones

Doble Criterio:

$$|\text{int}(\text{pixel}) - \text{int}(\text{semilla})| < 65$$

Conectividad grado 8



Semillas (i=255)

Contornos de las
regiones segmentadas



2

Definición del criterio de similitud (predicado)

- Dependiendo del criterio, la región puede crecer inadecuadamente

3

Definición del criterio de parada


- Dependiendo del criterio, la región puede crecer inadecuadamente

Ejemplo de dependencia del criterio de similitud



q es el píxel semilla

8	10	8	9	8	8	10	8	9	8	8	10	8	9	8
15	14	12	12	5	15	14	12	12	5	15	14	12	12	5
16	2	10	11	12	16	2	10	11	12	16	2	10	11	12
18	22	5	8	6	18	22	5	8	6	18	22	5	8	6
20	5	3	4	3	20	5	3	4	3	20	5	3	4	3



Un nuevo píxel se incluirá dentro de la región si la diferencia entre el nivel de gris del píxel y la media de los niveles de gris ya incluidos dentro de la región es menor que un umbral

División y fusión





Inicio

- Subdividir la imagen R en 4 cuadrantes disyuntos R_i .

División


- Subdividir cada región R_i que no cumpla con un predicado de homogeneidad Q ($Q(R_i) = \text{FALSO}$) en cuatro cuadrantes disyuntos.
- Cuando no se pueda dividir más, pasar a fusión.

Fusión

- Fusionar todo par de regiones adyacentes R_j y R_k que tales que $Q(R_j \cup R_k) = \text{VERDADERO}$.
- Parar cuando no se pueda fusionar más.


Variación: fusionar dos regiones adyacentes si cada una por separado satisface el predicado de homogeneidad

Quadtree: resultado de la división




Quadregions

Ejemplo de segmentación por el método de división y fusión de regiones



$P(R_i) = \text{VERDADERO}$ si todos los píxeles de R_i tienen la misma intensidad

Ejemplo de segmentación por el método de división y fusión de regiones



- Imagen del bucle de Cygnus.
- Se desea segmentar el anillo de materia menos densa alrededor del centro denso.
- Características de la región de interés:
 - Desviación estándar superior a la del fondo (que es cero) y a la de la región del centro (que es más homogénea)
 - Intensidad promedio superior a la del fondo oscuro e inferior a la del centro claro



$$Q = \begin{cases} \text{VERDADERO} & \text{si } \sigma > a \text{ y } 0 < \mu < b \\ \text{FALSO} & \text{de lo contrario} \end{cases}$$


En las
quadregions

Ejemplo de segmentación por el método de división y fusión de regiones



Imagen de la supernova Cygnus Loop. Se desea segmentar el anillo de materia menos densa alrededor del centro denso

Resultado con un tamaño mínimo de quadregion de 16x16



Resultado con un tamaño mínimo de quadregion de 32x32

Resultado con un tamaño mínimo de quadregion de 8 x 8


$$Q = \begin{cases} \text{VERDADERO} & \text{si } \sigma > \textcircled{a} \text{ y } 0 < \mu < \textcircled{b} \\ \text{FALSO} & \text{de lo contrario} \end{cases}$$

Para determinar a y b, se analizaron varias regiones del anillo y se constató que la intensidad promedio de los píxeles no excedía el valor 125 (b) y que la desviación estándar siempre fue superior a 10 (a).

Ejemplo de segmentación por el método de división y fusión de regiones



Imagen de la supernova Cygnus Loop. Se desea segmentar el anillo de materia menos densa alrededor del centro denso



Mejor resultado

Segmentación demasiado gruesa

Aparecen muchas quadregions pequeñas que no cumplen con Q


$$Q = \begin{cases} \text{VERDADERO} & \text{si } \sigma > \textcircled{a} \text{ y } 0 < \mu < \textcircled{b} \\ \text{FALSO} & \text{de lo contrario} \end{cases}$$

Los píxeles dentro de una quadregion que cumple el predicado se vuelven blancos, los demás de la región se ponen negros

Segmentación por *clustering*



¿Qué es clustering?



Encontrar k grupos de objetos que son similar entre sí y diferentes a objetos de otros grupos. (Bacher 1996)

K-Means

K-means es un algoritmo de clasificación no supervisada (clusterización) que agrupa objetos en k grupos basándose en sus características. El agrupamiento se realiza minimizando la suma de distancias entre cada objeto y el centroide de su grupo o cluster. Se suele usar la distancia cuadrática.

Inicialización

- Una vez escogido el número de grupos, k , se establecen k centroides en el espacio de los datos, por ejemplo, escogiéndolos aleatoriamente.

Asignación objetos a los centroides

- Cada objeto de los datos es asignado a su centroide más cercano.



Se repiten los pasos 2 y 3 hasta que los centroides no se mueven, o se mueven por debajo de una distancia umbral en cada paso.

Actualización centroides


- Se actualiza la posición del centroide de cada grupo tomando como nuevo centroide la posición del promedio de los objetos pertenecientes a dicho grupo.




K-means




K-means



K-means




K-means




K-means




K-means




K-means



K-means



K-means



Segmentación
por K-means
con $k=3$



Segmentación por *súper-píxeles*



SLIC (Simple Linear Iterative Clustering)

Dado un número de súperpixeles (sp), y una representación vectorial de cada pixel de la forma:

$$z = \begin{bmatrix} r \\ g \\ b \\ x \\ y \end{bmatrix}$$

En donde r,g,b son las componentes de color y x,y las coordenadas, este algoritmo busca generar divisiones de aproximadamente la misma área de pixeles “cercanos”.



SLIC (Simple Linear Iterative Clustering)

1. Calcular los centros de los súper píxeles iniciales, muestreando la imagen a intervalos regulares y mover los centros de los grupos al gradiente más bajo en un vecindario 3×3 .
 $d(p) = \infty$
 $L(p) = -1$
2. Para cada centro de grupos m_i , calcular la distancia de los centros a cada pixel en un vecindario $2s \times 2s$ alrededor del centro, y actualizar las distancias y los grupos para cada uno (si es la menor distancia).
 $d(p) = D_i$
 $L(p) = i$
3. Recalcular los centros de todas las regiones.
 $m_i = \frac{1}{|C_i|} \sum_{z \in C_i} z$
4. Calcular la diferencia entre las normas euclidianas de los vectores de los puntos entre el paso 1 y 3, y el error residual. Si la distancia obtenida es menor a un ϵ , acabar. De lo contrario, continuar iterando.
5. Reemplazar cada súperpixel en cada región por su intensidad promedio.



SLIC (Simple Linear Iterative Clustering)

